

GPU Cloud事業

数理モデルの構造と信頼性

—

U-NEXT / GMO GPU Cloud の投資判断モデルを
数式・データソース・信頼区間の観点から解剖する

16

校正済みパラメータ

15

スライド数


10K

モンテカルロ試行

11/11


バリデーション合格

モデルは3層構造



価格関数 $P(t)$

$$P(t) = P_0 \times (1 - \delta(t))^t \times DS(t)$$



各変数の意味

● $P_0 = 47.5$ 万円/月

HIGH

GMO公開料金（専有380万/8GPU）から直接取得

● $\delta(t)$ = 年間価格下落率

MED

初期30%→定常5%へロジスティック減速。
H100実績（\$9→\$2, $R^2=0.978$ ）で校正

● $DS(t)$ = 需給バランス比

LOW

$(1+g_d)^t / (1+g_s)^t$
需要25% vs 供給35%。直接データなし

価格関数の導出根拠

関数の説明

$$P(t) = P_0 \times (1 - \delta)^t \times \text{clip}(DS(t), 0.25, 1.3)$$

GPUの月額レンタル価格が、(1)技術陳腐化による自然減価と(2)需給バランスの2要因で変動するモデル。指数減衰 + 需給乗数の積として表現。

導出に使用したデータ

HIGH $P_0 = 47.5$ 万円/月

LOW $DS(t)$ 需給バランス比

データ: 直接データなし。以下の間接情報から構成:

- ・ 需要成長率 $g_d=25\%$: 4社の市場調査CAGR中央値 (MarketsandMarkets 26.5%, Fortune BI 35.8%, Mordor 28.74%, Grand View 16.0%) の保守的下限

- ・ 供給成長率 $g_s=35\%$: H100価格60-70%下落 (供給>需要の証拠) と300社以上の新規参入から逆算した推定値

導出: $DS(t) = (1+g_d)^t / (1+g_s)^t$ 。需要・供給がそれぞれ指数成長すると仮定し、その比で需給バランスを表現。clip(0.25, 1.3)で極端値を制限。

△ 信頼性が低い理由: g_s に直接統計が存在しない。 g_d は調査会社間で16~36%と2倍以上の乖離。両者の比がモデル結果を支配するため、この不確実性がNPVに最大の影響を与える (感度分析で確認済み)。

GMO GPU Cloud料金ページから直接取得。専有プラン月額380万円/台(8GPU) ÷ 8 = 47.5万円/GPU。公開価格なので信頼性は最高。

MED **$\delta = 10 \sim 15\%$ /年** (定常期)

データ: Silicon Data H100 Rental Index (SDH100RT) — Bloomberg公開の日次GPU価格指数。2023-01～2026-01の17データポイント（うち公式index値7点）。


導出: $P(t) = (P_0 - P_{\text{floor}}) \times e^{(-\lambda t)} + P_{\text{floor}}$ でフィッティング。全期間 $\lambda \approx 0.042$ /月（年率39.5%）だが、これは初期バブル崩壊を含む。定常期（2024-09以降） $\lambda \approx 0.030$ /月（年率30%）。5年スケールでは10-15%/年に収束すると仮定。

⚠ 注意: H100の2年分のデータから10年分を外挿。半減期16.5ヶ月は実測だが、floor近傍での長期挙動は未検証。

関数形の仮定: 指数減衰×需給乗数という関数形自体がモデル仮説。実際の価格変動はAWSの突発的値下げ（2025-06に44%値下げ）などステップ関数的に起こることが多く、連続関数による近似の限界がある。Epoch AI研究ではGPU FLOP/\$の倍増期間は2.46年（95% CI: 2.24-2.72年）であり、年率10-15%の定常下落は歴史的傾向とおおむね整合。

稼働率関数 $U(t)$

$$U(t) = R(t) \times U_0 \times C(t) \times D(t)$$



4つの構成要素

R(t) ランプアップ

MED

S字カーブ。GMO実績: 9ヶ月で月次黒字化

U₀ 初期稼働率 = 75%

MED

GMO月次黒字化→50%超は確実。業界平均15-30%との乖離大

C(t) 競合圧力

LOW

$\max(1 - \alpha \times N_{\text{new}}, 0.5)$ 。α=0.015はモデル固有。実績校正なし

D(t) 需要ブースト

LOW

$\text{clip}(\text{DS}(t), 0.7, 1.15)$ 。需給比から派生

稼働率関数の導出根拠

関数の説明

$$U(t) = \text{clip}(R(t) \times U_0 \times C(t) \times D(t), 0.35, 0.95)$$

GPUの実効稼働率を、(1)ランプアップ、(2)初期水準、(3)競合圧力、(4)需要ブーストの4要因の積として表現。最低35%～最高95%にクリップ。

各構成要素の導出

MED **R(t):** ランプアップ (S字カーブ)

データ: GMO実績 — 2024年11月サービス開始、9ヶ月後 (2025年Q3頃) に月次黒字化達成。

導出: ロジスティック関数 $R(t) = 1 / (1 + e^{-(k(t-t_0)})}$

LOW **C(t) = max(1 - $\alpha \times \Delta N$, 0.5):** 競合圧力

データ: 2024-25年の国内GPU Cloud新規参入実績: GMO, さくら(拡張), KDDI, ハイレゾ(拡張), ルチラ(拡張), SB(拡張) → 約3社/年。さくらの下方修正 (158億 → 90-110億) は競争激化の間接証拠。

導出: $\alpha=0.015$ (新規参入1社あたり1.5%の稼働率低下) はモデル固有のパラメータで、実績校正されていない。最低50%の「床」は市場撤退による自然減を想定。

△ 信頼性が低い理由: α の値に実証的根拠がない。実際にはハイパースケーラー (AWS/GCP) 1社の値下げが独立系10社の参入より影響が大きい、その異質性は未モデル化。線形仮定も非現実的 (閾値効果がある)。

LOW

t_mid))). t_mid≈4.5ヶ月（中間点）、k≈1.5（傾き）。9ヶ月で95%到達。

△ 注意: GMO固有の実績。DC構築→テスト→顧客オンボーディングに通常6-18ヶ月必要とされ、9ヶ月は業界的に速い方。新規事業者では12-18ヶ月が現実的。

MED **U₀ = 75%:** 初期定常稼働率

データ: GMO「月次黒字化達成」→損益分岐稼働率(～50%)超過は確定。チューリング4年32億円契約等の長期案件あり。業界平均は15-30% (Aethir, Thunder Compute報告)。CoreWeave（長期契約型）は85%超。

導出: 損益分岐(50%) < U₀ < CoreWeave水準(85%)の中間値として75%を仮定。

△ 注意: GMOの正確な稼働率は非公開。月次黒字化は50%超の下限を示すが、上限の根拠が弱い。レポートによっては80%と仮定する場合もある。

D(t) = clip(DS(t), 0.7, 1.15): 需要ブースト

データ: P(t)のDS(t)と同じ需給バランス比から派生。

導出: 需要超過(DS>1)時に稼働率が最大15%改善、供給過多時に最大30%低下と仮定。clip範囲(0.7～1.15)は経験的推定。

△ 信頼性が低い理由: DS(t)自体が低信頼度であることに加え、clip範囲の設定に実証的根拠がない。需給→稼働率の因果メカニズムも単純化されている。

構造的課題: 「稼働率-単価トレードオフ」が未モデル化。高稼働率の源泉である長期契約は30-50%割引を伴うが、本モデルはU₀=75%とP₀=47.5万円を独立に仮定。チューリング契約実績(～40万円/月)は既に16%低い。

売上とコストの数式

売上

$$\text{Rev}(t) = \sum [N_{\text{gpu}} \times P(t) \times \beta \times U(t) \times 12]$$

H200: 1,024基 × P(t) × 1.0 × U(t) × 12

B300: 200基 × P(t) × 1.8 × U(t) × 12

GPU基数 × 月額単価 × プレミアム × 稼働率 × 12ヶ月
 現実との対応: 各GPUの時間貸し売上の年間合計


電力コスト

$$\text{Elec}(t) = \text{kW} \times \text{PUE} \times 8760\text{h} \times \text{Rate}(t) \times [\eta + (1-\eta) \times U(t)]$$

固定分: アイドル電力 (TDPの40%)
 変動分: 稼働時追加電力

コスト構造 (現実との対応)

Y1 費用構成 (億円)



Y1 売上 vs コスト



売上・コスト関数の導出根拠

売上関数

$$\text{Rev}(t) = \sum_i [N_i \times P_i(t) \times \beta_i \times U(t) \times 12] / 10^4$$

説明: DC事業の第一原理「容量×単価×稼働率」を数式化。GPU基数(N)、月額単価(P)、プレミアム倍率(β)、稼働率(U)、12ヶ月の積。

データ:

- ・ N_H200 = 1,024基 **HIGH** GMO公表 (96→128ノード×8GPU)
- ・ N_B300 = 200基 **MED** GMO IR発表 (25ノード×8GPU)
- ・ β_B300 = 1.8倍 **LOW** Hyperstack B300 vs H200実勢価格比から推定。市場データ1.5-3倍の間。B300の正式価格は未公開

固定OPEX

LOW 固定運営費 = 12.4億円/年

内訳と信頼性:

- ・ 人件費 2.4億円: 30名×800万円と仮定。GMO非公開。GPU専門人材は年収1,000-1,500万円が相場であり、過少の可能性
 - ・ DC賃料 2.0億円: 福岡の借用型DC。個別費目はGMO非公開
 - ・ 保守費 1.5億円: GPU故障率2-5%/年からの推定
 - ・ NW費 0.8億円: 業界実態では1.5-3.0億円の可能性
 - ・ SW費 0.4億円: NVIDIA AI Enterprise (\$4,500/GPU/年)を含めると2.0億円以上の可能性
 - ・ 営業費 1.0億円 / 管理費 0.5億円
- △ 信頼性が低い理由: 個別費目はいずれもGMO非公開。合計コスト (約24億円) との整合から逆算した推

検証: Y1売上~27.4億円は、GMOの「初年度推定20-40億円」の範囲内。

定値。3チーム統合レビューでは年間5-14億円の過少評価の可能性を指摘。

電力コスト関数

$$E(t) = \sum_i N_i \times W_i \times [\eta + (1-\eta) \times U(t)] \times PUE \times 8760 \times r_e / 10^8$$

説明: 電力コストを「固定（アイドル電力）+変動（負荷比例電力）」の混合構造として分離。GPUはアイドル時もTDPの~40%を消費するため、電力費の大部分は固定費。

データ:

- ・ $W_{H200} = 700W$ **HIGH** NVIDIA公式TDP
- ・ $W_{B300} = 1,200W$ **HIGH** DGX B300 HGX版公式
- ・ $\eta = 40\%$ **MED** GPU単体15-20% + CPU/メモリ/NIC等のシステムベース電力でTDP全体の~40%。DC業界一般則30-60%の間
- ・ $PUE = 1.30$ **MED** JDCC調査、日本最新DC 1.2-1.4の間

減価償却

HIGH $Dep = CAPEX_{net} / 5年$

データ: CAPEX 100億円（GMO公表）、助成金19.3億円（経産省認定）。法定耐用年数5年（国税庁「サーバー」）。定額法を想定。

注意: 定率法の場合は初期に償却が集中し、税シールド効果でNPV +3~8%の上振れ要因。また、経済的耐用年数はGPU世代交代（~2年サイクル）を考慮すると3-4年が妥当だが、会計上は5年で処理。

コスト関数全体の信頼性: 減価償却（HIGH）が費用の60%を占めるため、コスト合計の精度は中程度。ただし欠落項目（SWライセンス、冗長性インフラ、スペアパーツ等）により総コストは20-55%過少評価の可能性がある。

投資判断指標の算出

$$FCF(t) = (\text{営業利益} - \text{Tax}) + \text{減価償却} - \text{CAPEX}$$

$$NPV = \sum FCF(t) / (1+r)^t$$

-98.5

NPV (億円)

$$\text{IRR: } NPV(r)=0 \text{ を解く}$$

N/A

IRR (WACC=8%)


$$\text{累計FCF} \geq 0 \text{ の年}$$

>15

回収期間 (年)

ベースケースの意味: 全パラメータを中央値に設定しても投資回収不能。
売上（価格×稼働率）の減少速度がコスト削減を上回り、赤字が拡大する構造。

モンテカルロシミュレーション



確率的判断

NPV > 0 の確率

9.3%

IRR > WACC(8%)

28.1%

10年以内回収

16.8%


注意: これらは「正確な確率」ではない。パラメータの独立性仮定、分布の形状仮定、構造的な不確実性（数式自体の妥当性）を含まない条件付き推定値。

全16パラメータと信頼性

パラメータ	中央値	データソース (現実世界の対応)	信頼度
P ₀ 月額単価	47.5万円	GMO料金ページ: 専有380万/8GPU	HIGH
電力単価	20円/kWh	Statista 2025 + 経産省 再エネ賦課金	HIGH
法人税率	30%	PwC Japan 法定実効税率 30.62%	HIGH
δ 価格下落率	15%/年	H100実績 \$9→\$2 (R ² =0.978)、定常期	MED
g_demand 需要成長	25%	4社市場調査中央値 (16-36%)	MED
U ₀ 初期稼働率	75%	GMO月次黒字化 (間接証拠)	MED
PUE	1.30	JDCC調査、2026規制上限1.40	MED
WACC	8%	GMO CAPM β=0.47 + リスクプレミアム	MED
ランプアップ期間	9ヶ月	GMO実績 2024/11→2025/Q3黒字化	MED
アイドル電力比	40%	NVIDIA公式TDP + DC業界一般則	MED


g_supply 供給成長	35%	価格下落からの逆推定（直接データなし）	LOW
α 競合感度	0.015	モデル固有。さくら下方修正で間接校正	LOW
U_min 最低稼働率	35%	業界平均15-30% + ロックイン効果推定	LOW
SW ライセンス	2.0億/年	NVIDIA AI Enterprise リスト÷割引推定	LOW
人件費	3.5億/年	GPU専門人材市場価格推定	LOW
B300プレミアム	1.8x	Hyperstack B300 vs H200 実勢価格比	LOW

感度分析 — 何が**NPV**を動かすか



最大のリスク: NPVを最も左右する上位2パラメータ（供給・需要成長率）は、いずれも信頼度が低い

ストレステスト — 極端シナリオ



価格崩壊

-195億AWS 50%値下げ
+供給過多

需要蒸発

-190億推論効率10x改善
+景気後退

コスト爆発

-129億電力高騰
+NVIDIA値上げ

複合最悪

-236億全リスク
同時顕在化

楽観

+148億需要爆発
+供給制約

このモデルで言えること・言えないこと

言えること

- GPU価格は年15-30%下落が続く

$R^2=0.978$ 、11点の実績データで検証

- 費用構造は固定費支配（80%超）

CoreWeave S-1と構造的に一致

- 稼働率が損益を決定的に左右する

損益分岐稼働率 ~85% (Y1)

- ベースケースでは投資回収困難

NPV -98.5億円（中央値パラメータ）

- 最大リスクは需給バランスとSWコスト

感度分析で定量的に確認

言えないこと

- ⚠ 投資回収の「正確な確率」

9.3%は条件付き推定。真の確率ではない

- ⚠ 5年後以降の市場構造

次世代GPU、量子計算等の構造変化は含まない

- ⚠ 不連続イベントの影響

大口解約、NVIDIA政策転換、規制変更

- ⚠ パラメータ間の相関構造

独立サンプリングで過度に分散する

- ⚠ 数式モデル自体の妥当性

DS(t)や α 等の関数形は仮説にすぎない

モデルの結論

GPU Cloud事業は構造的に固定費が重く、価格下落と競合激化の中で持続的な黒字化が困難な事業モデル。ただし楽観シナリオでは高リターンの可能性も存在する。

信頼できる構造

3層DCF

価格減衰 $R^2=0.978$
CoreWeave整合
11/11バリデーション

不確実性の核心

需給

供給成長率: LOW信頼度
NPV変動幅 164億円
直接データなし

投資判断への示唆

慎重

NPV>0: 9.3%
ダウンサイドが非対称
段階的投資が合理的

モデルは「答え」ではなく「思考の枠組み」。
どのパラメータが変われば結論が変わるかを示すことに価値がある。